

| iPlant eindverslag

Groep D: Nathan Vandekerckhove, Robbe Van den Broek, René
Goossens, Quinten van de Korput

18 december 2020

Begeleiders: Zimcke Van de Staey, Natacha Gesquière, Francis wyffels

SAMENVATTING

Het project iPlant probeert een idee te krijgen over de invloed door de klimaatopwarming op planten. Fotosynthese speelt een grote rol bij de klimaatopwarming waarbij de stomata een belangrijke factor zijn. Zij bepalen de in- en uitvoer van gassen van de plant en bepalen dus mee de fotosynthese-intensiteit van de plant. Een analyse van de evolutie van de huidmondjes kan inzichten bieden over het toekomstige klimaat. Bovendien worden enkele aspecten van artificiële intelligentie besproken zoals de voor- en nadelen en enkele toepassingen. Om het tellen van de stomata te automatiseren wordt gebruik gemaakt van een convolutioneel neurale netwerk. Vooraleer een afbeelding kan worden geanalyseerd door een computersysteem moet eerst een digitale afbeelding numeriek voor worden gesteld. Een convolutie is een bewerking die bepaalde eigenschappen van een afbeelding kan detecteren. Op deze manier wordt informatie opgehaald over de afbeelding die verwerkt wordt door het neurale netwerk. Het netwerk leert dan welke combinatie van kenmerken een huidmondje voorstelt met behulp van een leeralgoritme. Het netwerk dat opgesteld werd bestaat uit vier convolutionele lagen en drie lagen uit het neurale gedeelte. In dit verslag gaan wordt dieper ingegaan op de werking van het classificatiemodel en de voornaamste parameters.

Inhoudsopgave

Samenvatting	2
Verklarende woordenlijst	4
1. Inleiding	5
2. Artificiële Intelligentie	5
2.1. Belang van artificiële intelligentie	5
2.2. Bias	5
2.3. Valkuilen	6
2.4. Toepassingen	6
3. Werking van stomata	6
3.1. Fotosynthese.	6
4. Afbeeldingen	7
4.1. RGB	7
4.2. Grijswaarden	7
5. Convolutioneel Neuraal netwerk	7
5.1. Convolutionele filters	7
5.2. Neuraal netwerk	7
5.3. Artificieel neuron	8
5.4. Het Perceptron	8
5.5. Activatiefuncties	8
5.6. Hidden layers	9
5.6.1 Voorbeeldtoepassing hidden layer	9
6. iPlant	9
6.1. Belang van het onderzoek	9
6.2. Verkrijgen van data	10
6.3. Tellen van huidmondjes	10
6.4. Stomatale densiteit	10
6.5. Detectie van stomata	10
6.5.1. Parameters	10
Referenties	13

VERKLARENDE WOORDENLIJST

Convolutioneel neuraal netwerk: Dit is een klasse van diepe neurale netwerken, die meestal worden toegepast voor het analyseren van visuele beelden. [1]

Training data: Dit is een initiële set van data om een programma te helpen begrijpen hoe technologieën zoals neurale netwerken kunnen worden toegepast om hieruit te leren en om geavanceerde resultaten te produceren. [2]

Invoerapparaten: Dit zijn alle apparaten waarmee gegevens in een computer kunnen ingevoerd worden. Een paar voorbeelden hiervan zijn het toetsenbord, muis, joystick, gamepad, grafisch tableau, aanraakscherm, scanners en digitale camera's. [3]

Broeikasgas: Dit zijn gassen in de atmosfeer van de Aarde of een andere planeet die het vermogen hebben om warmtestraling te absorberen en deze ook geleidelijk aan in alle richtingen weer af te geven.[4]

Lineair scheidbaar: De mogelijkheid om alle data te scheiden door middel van één rechte.[7]

Hidden layer: Een laag tussen de input- en de outputlaag, waar neuronen inputs binnenhalen en een output produceren door middel van een activatiefunctie.[14]

Convolutie: Een wiskundige bewerking van twee functies waaruit een derde functie gevormd wordt. Deze functie toont aan hoe de vorm van de ene functie gewijzigd wordt door de andere. [18]

Classificatie: Het indelen of samennemen van bepaalde objecten in groepen. Dit doet men aan de hand van de overeenkomst in eigenschappen.[19]

1. INLEIDING

In dit eindverslag worden de sessies rondom het project iPlant besproken. Gedurende dit verslag wordt een antwoord gegeven op de vraag: Wat is de invloed van de klimaatopwarming op planten? Het doel van het project was om een zo goed mogelijk functionerend neurale netwerk op de bouwen. Dit netwerk kan daarna gebruikt worden om sneller een besluit te bekomen over de invloed van de klimaatopwarming. Eerst is het belangrijk enkele begrippen rondom stomata en neurale netwerken te begrijpen.

2. ARTIFICIËLE INTELLIGENTIE

Artificiële intelligentie is de wetenschap die zich bezighoudt met het creëren van een zelfgemaakt voorwerp dat een vorm van intelligentie vertoont. Tijdens het ingenieursproject werd vooral gefocust op machine learning, dit is een subset van artificiële intelligentie. Machine learning is de studie van computeralgoritmen die automatisch verbeteren door ervaring. Algoritmen voor machine learning bouwen een model op basis van voorbeeldgegevens, deze voorbeeldgegevens worden “training data” genoemd. Met machine learning kunnen computers aan het werk gezet worden zonder dit expliciet te programmeren. In de afgelopen jaren heeft machine learning ons zelfrijdende auto's, praktische spraakherkenning, effectief zoeken op internet en een enorm verbeterd begrip van het menselijk genoom opgeleverd. Nog een belangrijke AI-functie die wij hebben gezien tijdens iPlant is deep learning. Dit is een AI-functie die de werking van het menselijk brein imiteert. Dit kan worden toegepast bij het verwerken van gegevens en het creëren van patronen. Dit netwerk kan helpen om een besluit te maken.[12][13][14]

2.1. Belang van artificiële intelligentie

Vandaag de dag is de hoeveelheid gegevens die wordt gegenereerd, zowel door mensen als door machines, veel groter dan het vermogen van de mens om te absorberen, te interpreteren en complexe beslissingen te nemen op basis van die gegevens. Artificiële intelligentie vormt ook de basis van al het computer leven en het is ook de toekomst van alle complexe besluitvorming. In het project iPlant was artificiële intelligentie ook van uiterst belang. Ons doel was om stomata te kunnen detecteren op een foto. Aangezien dit veel inspanning en moeite vereist om dit op elke foto zelf te doen, wordt gebruik gemaakt van

artificiële intelligentie. Er wordt een neurale netwerk geprogrammeerd dat zal beslissen of er op de foto een stomata aanwezig is.[13]

2.2. Bias

Een belangrijk onderwerp dat we tijdens iPlant hebben behandeld is bias. Er is sprake van bias wanneer externe factoren een negatieve invloed hebben op de uitkomsten van een onderzoek. Het gevolg hiervan is dat de uitkomsten geen goede afspiegeling zijn van de werkelijkheid en daarmee hun nut en meerwaarde verliezen. Culturele bias is gebaseerd op de aannames die men zou kunnen hebben vanwege de cultuur waarin ze zijn opgegroeid. Met andere woorden, verschillende interpretaties bij verschillende situaties.

Bij artificiële intelligentie bestaan er drie soorten bias: pre-existing bias, technical bias en emergent bias. Pre-existing bias is ingebouwd in het systeem. Dit kan voorkomen in de trainingsdata of in de software zelf. De software weerspiegelt dan vooroordelen van de organisatie. Technical bias vloeit voort uit technische beperkingen en overwegingen zoals beperkte ruimte op een scherm, maar ook invoerapparaten en specifieke algoritmen kunnen een systeem beïnvloeden. Ten slotte is er nog de emergent bias, het gebruik van een softwaresysteem verandert in de loop van de tijd. Daardoor ontstaat er bias die moeilijk tot zelfs onmogelijk was te voorspellen toen het systeem werd gebouwd. Deze bias kan ontstaan door nieuwe soorten bronnen of door de toevoeging van nieuwe gebruikers.[25][26]

In het ingenieursproject iPlant komen ook verschillende bias voor. Onder andere bij de verwerking van data. Dit kan omdat er niet voldoende data is gegeven of de data incorrect is ingevoerd. De data kan ook niet representatief zijn, er kan bijvoorbeeld al een conclusie getrokken worden door tien test exemplaren te bekijken. Uiteraard zorgt dit ervoor dat de uitkomst van het onderzoek niet volledig correct is door het gebrek aan data. Ook kan er bias optreden bij het detecteren van stomata op de foto's. De oorzaak hiervan is dat de foto's niet voldoen aan de juiste eisen. Zo kunnen de stomata een verschillend formaat of kleur hebben. Pre-existing bias komt hier ook voor omdat stomata vanuit een ander werelddeel een andere vorm kunnen aannemen. Deze bias komt voor in de trainingsdata als slechts enkele verschillende soorten stomata voorkomen.

2.3. Valkuilen

Machine learning heeft zeer veel toepassingen, maar niet alle toepassingen lopen van in het begin goed. Machine learning heeft namelijk ook valkuilen. Een eerste valkuil is dat het niet direct implementeerbaar is. De parameters moeten zorgvuldig worden bepaald en vervolgens moeten de toepassingen voldoende worden getraind. Het trainingsproces loopt verder nadat de machine al in gebruik genomen is waardoor het systeem slimmer wordt naarmate het langer in gebruik is. Een tweede valkuil is het prijskaartje. Wanneer machines worden toegepast in arbeidsgebieden is het soms niet mogelijk deze direct te verdelen onder iedereen. Dergelijke machines zijn duur en dus niet altijd financieel haalbaar. Ten derde is het systeem niet altijd volledig foutloos en bestaat de mogelijkheid tot defecten. Het kan even duren voor het defect verholpen is en het systeem terug in gebruik kan worden genomen.

Tot slot is er ook de kwestie rond werkzekerheid. Machinaal leren zal veel jobs doen verdwijnen, maar het zal even goed nieuwe jobs creëren. Het is belangrijk om hier rekening mee te houden en te voorkomen dat geen te groot deel van de bevolking benadeeld wordt.

2.4. Toepassingen


In machine learning zijn er ontelbaar veel toepassing, er worden een paar toepassingen meegegeven zodat er een duidelijk beeld wordt gevormd wat machine learning is. In de landbouw zijn er ondertussen al een substantieel aantal toepassingen van machine learning. Deze toepassingen zijn de laatste jaren in opmars. Een voorbeeld hiervan zijn slimme sproeiers. Dit zijn vooraf-geprogrammeerde sproeiers die een bepaald traject afleggen en zo de gewassen voorzien van een genoeg aan water of eventuele pesticiden. Daarnaast zijn er ook machines die de oogst keuren. Zo scant men bijvoorbeeld druiven en worden de rotte druiven gedetecteerd. Deze worden dan weggeblazen van de band. Bovendien werkt men de laatste jaren aan 'slimme stallen'. Een slimme stal kan gegevens verzamelen over het klimaat in en rond uw bedrijf, de gezondheid van de dieren en de geuruitstoot. Het geeft ook een inzicht op het waterverbruik in de stal. Hierdoor kan direct actie ondernomen worden als de stal iets detecteert wat abnormaal is.[7]

3. WERKING VAN STOMATA

Stomata zijn een belangrijk onderwerp in het project iPlant. Stomata zijn kleine poriën die op het bladoppervlak van de plant voorkomen. Deze huidmondjes staan in voor de gaswisseling van een plant. Langs deze cellen worden gassen zoals koolstofdioxide in de plant opgenomen en gassen zoals waterdamp en zuurstofgas kunnen de plant verlaten door stomata. De meeste van deze stoffen worden gebruikt of geproduceerd bij de fotosynthese, een van de meest essentiële processen binnenin de plant. Daarom is het belangrijk om een idee te hebben hoe de fotosynthese werkt.[23][24]

3.1. Fotosynthese.

In de planten wordt lichtenergie omgezet tot chemische energie door de fotosynthese. Voorbeelden van chemische energie zijn glucose en andere organische stoffen. Voor het proces te laten doorgaan is de aanwezigheid van CO₂ noodzakelijk. Het organisme moet zich ook in het licht bevinden. Fotosynthese is een belangrijk proces in de strijd tegen de klimaatopwarming en bepaalt grotendeels het leven op Aarde. Dit wordt duidelijk uit de chemische reactie omdat er een broeikasgas, koolstofdioxide, opgenomen wordt. Ook wordt er zuurstofgas uitgestoten wat noodzakelijk is voor mensen en vele andere organismen.[19][20]



Het fotosyntheseprocess bestaat uit twee belangrijke onderdelen: de lichtafhankelijke reacties en de lichtonafhankelijke reacties. De eerste stap in het proces zijn de lichtafhankelijke reacties. In deze reacties wordt lichtenergie opgenomen door pigmenten. Licht wordt ingedeeld op basis van de golflengte in het elektromagnetisch spectrum. Elk pigment neemt een bepaalde golflengte van het elektromagnetisch spectrum op. De energie opgenomen in de pigmenten brengt de elektronen naar een hoger energieniveau. De elektronen verplaatsen zich door een elektronentransportketen waarin de energie wordt afgegeven in de vorm van ATP en NADPH, twee energierijke moleculen. Na de lichtafhankelijke reacties volgen de lichtonafhankelijke reacties. In deze reacties wordt CO₂ door middel van meerdere tussen moleculen omgezet tot organische moleculen waarvan C₆H₁₂O₆ ofwel glucose de voornaamste is.[19][20]

4. AFBEELDINGEN

Aangezien er in het onderzoek gebruik wordt gemaakt van microscopische foto's om een inschatting te maken in welke vorm en hoeveelheden de stomata voorkomen is het belangrijk om te begrijpen hoe afbeeldingen opgebouwd zijn en hoe ze verwerkt worden in python. Afbeeldingen bestaan uit vele pixels die elk een bepaalde kleur hebben. Alle pixels samen vormen de afbeelding. Voor het inladen van de afbeelding in python wordt gebruik gemaakt van de functie `imread()` van de module `matplotlib.pyplot`. Deze functie maakt een tensor van de afbeelding in RGB.[7]

4.1. RGB

De meeste foto's worden tegenwoordig in kleur getrokken. Als deze afbeeldingen ingelezen worden in python wordt er gebruikgemaakt van een tensor om deze afbeeldingen weer te geven. Tensoren zijn meerdere lagen van matrices met dezelfde dimensie die op elkaar worden geplaatst. De verschillende kleuren kunnen op verschillende manieren gecreëerd worden. Python maakt gebruik van RGB, dat staat voor rood, groen en blauw. Dit zijn drie waarden tussen 0 en 255 die gecombineerd worden om bijna elke kleur te kunnen creëren. De RGB-tensor van de afbeeldingen bestaat dus uit 3 matrices waarvan elk element waarden tussen 0 en 255 aanneemt. Als van de 3 matrices de elementen worden gecombineerd verkrijgt men de kleur per pixel.[7]

4.2. Grijswaarden

In het project wordt echter gebruikgemaakt van zwart-wit foto's. Dit komt omdat de kleur van een stomata een vorm is van bias. Door de afbeeldingen in grijswaarden te verwerken in het neurale netwerk wordt deze vorm van bias vermeden waardoor het netwerk accurater zal zijn. Grijswaarden worden in python weergegeven door waarden tussen 0 en 255. Waarbij 0 zwart is en 255 wit is. Alle waarden hiertussen corresponderen met een andere grijswaarde. Om afbeeldingen in kleur om te zetten naar grijswaarden wordt de module `skimage.color`. De bijbehorende functie `rgb2gray` zet de foto in grijswaarden en geeft waarden terug tussen 0 en 1. Om ook in python te kunnen werken met waarden tussen 0 en 255 wordt de matrix vermenigvuldigd met 255.[7]

5. CONVOLUTIONEEL NEURAAL NETWERK

Voor het tellen van de huidmondjes maakt men gebruik van een zogenaamd convolutioneel neurale netwerk. Voor zo'n netwerk geïmplementeerd wordt in het onderzoek is

het belangrijk te weten hoe zo'n netwerk werkt. Een convolutioneel neurale netwerk bestaat uit 2 delen. Het eerste gedeelte is het convolutioneel gedeelte, waarin filters op de foto worden toegepast om zo de juiste eigenschappen te activeren. Daarna begeeft de uitvoer van het convolutionele gedeelte zich in het neurale gedeelte waar deze wordt geclassificeerd.[7]

5.1. Convolutionele filters

Zoals eerder vermeld activeren convolutionele filters eigenschappen en kenmerken van een foto. Met een convolutie kan men bijvoorbeeld randen, schuine lijnen en verticale lijnen detecteren. Ook worden ze gebruikt voor aanpassingen in contrast en het uitfilteren van ruis. Convolutionele filters zijn vierkante matrices, die in verschillende dimensies voorkomen. Deze matrix schuift als het ware over de foto en past een bewerking toe bij elke stap. De waarden in de convolutionele filter worden vermenigvuldigd met de overeenkomstige waarden van de pixels en worden daarna opgeteld. Dit principe heet een gewogen som van de grijswaarden. Deze nieuwe waarde wordt nadien toegevoegd aan een nieuwe matrix waardoor men een aangepaste afbeelding verkrijgt.[7]

Bij het programmeren van deze filters en de bewerkingen in python maakt men gebruik van de module `scipy.signal` en de bijhorende functie `convolve2d()`. Deze functie voert de convolutionele bewerking uit op het gegeven deel van de afbeelding. Als resultaat krijgt men een nieuwe numpy array die overeenkomt met de gefilterde afbeelding. In een convolutioneel neurale netwerk voegt men meerdere convolutionele lagen achter elkaar toe. Elk van deze lagen bestaat uit meerdere convolutionele filters. Door het toevoegen van meerdere filters worden meer eigenschappen van de afbeelding geactiveerd. Hierdoor heeft het netwerk meer waarden om mee te werken. Dit leidt tot een effectiever en nauwkeuriger netwerk. [1][7]

5.2. Neuraal netwerk

Een neurale netwerk is een computersysteem dat wordt gehanteerd bij deep learning. Het bestaat uit een verzameling van eenheden of neuronen die met elkaar in verbinding staan in een gelaagde structuur. Er is een input en een outputlaag met daartussen een te kiezen aantal verborgen lagen. Het model is geïnspireerd door de werking van het biologische brein.[5][6]


Vooraleer een neurale netwerk operatief is, moet het getraind worden. Dit houdt in dat het netwerk zichzelf vormgeeft door te leren uit de trainingsdata. Deze dataset is vooraf manueel gelabeld met de gewenste klasse. Telkens het netwerk een input uit de trainingsdata verwerkt evalueert het zichzelf aan de hand van de het label. Als het niet het gewenste resultaat teruggeeft, past het systeem zelf zijn parameters aan in de goede richting. Eens het neurale netwerk voldoende getraind is, kan het de klasse van ongeziene data statistisch verantwoordt voorspellen.[5][6]

5.3. Artificieel neuron

De neuronen in een neurale netwerk worden artificiële neuronen genoemd. Gelijkaardig aan het verloop van een zenuwimpuls tussen verschillende biologische neuronen via de synaptische spleet, kan tussen artificiële neuronen een signaal worden doorgegeven. Dit signaal neemt dan de vorm aan van een reëel getal. Een artificeel neuron neemt een gewogen som van de verschillende verkregen inputs. De output van het neuron is het resultaat van deze som na inwerking van een bepaalde activatiefunctie. Elk neuron representeert een zekere eigenschap. De sterkte van deze eigenschap toont zich in de waarde van het neuron. Hoe meer neuronen in een laag, hoe meer eigenschappen waarmee rekening kan worden gehouden. In een convolutioneel neurale netwerk komt de input van het neurale gedeelte uit het convolutionele gedeelte. De eigenschappen in de neuronen zijn dan bepaalde kenmerken die door convoluties worden gedetecteerd.[5][6]

5.4. Het Perceptron

Deze zogenaamde gewichten in de lineaire combinatie zijn veranderlijke parameters. Door zelf deze parameters aan te passen indien de output niet correct is, stelt het systeem zichzelf in staat tot verbetering. Er kan dan gesproken worden van een neurale netwerk. Het Perceptron (Figuur 1) is het allereerste en meest eenvoudige neurale netwerk bestaande uit enkel een input- en outputlaag. [7]



Figuur 1: Het perceptron [7]

Eerst worden de gewichten (w) van het netwerk willekeurig gekozen. Het netwerk vergelijkt de eigen voorspelde klasse \hat{y} met het label y . De gewichten worden zo nodig aangepast indien incorrect. (2). Hierbij worden verschillende factoren in rekening gebracht: het verschil tussen de werkelijke waarde y en de voorspelde waarde \hat{y} , een gekozen learning rate η , en de invoer x :

$$w_j = w_j + \eta (y - \hat{y}) x_j \quad (2)$$

Met deze aangepaste gewichten komt de uitkomst dichter bij de juiste waarde te liggen. De trainingsdata wordt herhaaldelijk doorlopen tot het netwerk alles correct voorspeld. Een dergelijke cyclus noemen wordt een epoch genoemd.[7]



Figuur 2: Het trainingsalgoritme

5.5. Activatiefuncties

De activatiefunctie van het Perceptron is de Heaviside-functie of drempelwaarde-functie (figuur 1):

$$H(x) = \begin{cases} 0 & \text{voor } x < 0 \\ 1 & \text{voor } x \geq 0 \end{cases}$$

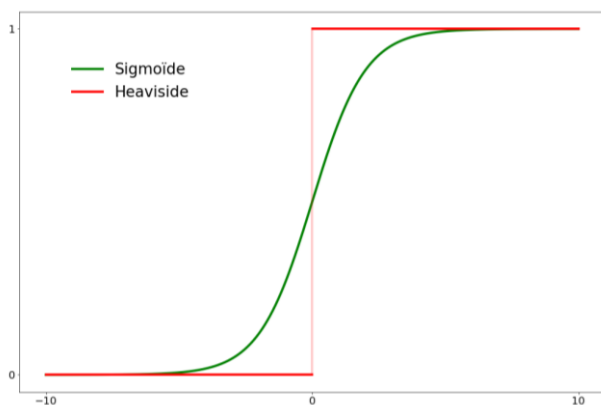
Een belangrijke vereiste om het Perceptron succesvol te kunnen gebruiken, is dat de data lineair scheidbaar is. De stopvoorwaarde in het Perceptron-algoritme is dan anders nooit voldaan (figuur 2). Dit houdt in dat het mogelijk moet zijn om de punten in een puntenwolk te scheiden in klassen door middel van een rechte. Wanneer dit niet het geval is moet men beroep doen op andere

activatiefuncties om dit probleem zoveel mogelijk te omzeilen.

Als de data op slechts enkele punten na lineair scheidbaar is kan het Perceptron vervangen door logistic regression. Hierbij doet de sigmoïd-functie of logistieke functie dienst als activatiefunctie:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$


De output is hier een waarde tussen 0 en 1 die weergeeft hoe zeker het systeem is dat een punt tot klasse 1 behoort. De sigmoïd als activatiefunctie is dus veel genuanceerder. Dit vereist echter wel de invoer van een bijkomstige hyperparameter: de drempelwaarde of threshold. Dit is de minimale zekerheid die het systeem moet hebben om een datapunt te classificeren. De Heaviside-functie is echter niet compleet minderwaardig dan de sigmoïde-functie als activatiefunctie. Als de data volledig lineair scheidbaar is, is het beter om de Heaviside te gebruiken omdat de sigmoïde dan soms alsnog fout kan classificeren.[7]



Figuur 3: Sigmoid- en Heaviside-functie

Een derde activatie-functie die wordt gebruikt binnen machine learning is de rectified linear unit of kortweg ReLU-functie. De functie beeldt de positieve invoer af op zichzelf en zet de negatieve invoer op 0. Ze wordt als volgt gedefinieerd:

$$\text{ReLU}(x) = \max(0, x)$$



Figuur 4: De ReLu activatiefunctie [20]

5.6. Hidden layers

Met slechts een input- en outputlaag is het Perceptron niet geschikt voor complexere classificatieproblemen. Om data lineair scheidbaar te kunnen maken is er nood aan een extra laag van neuronen tussen de input en output, een verborgen laag. In de praktijk is het vaak zo dat er meerdere verborgen lagen worden toegevoegd. De neuronen in een laag zijn telkens allemaal verbonden met de neuronen in de volgende, er kan dan gesproken worden van een feed forward-netwerk. De uitvoer van deze lagen is tijdelijk en blijft logischerwijze verborgen voor de gebruiker. Een neuraal netwerk volgt daardoor het Black Box-principe, het gedrag van het systeem is bekend maar niet altijd de inwendige werking.[7]

5.6.1 Voorbeeldtoepassing hidden layer

Een mogelijke toepassing van een hidden layer is om de data lineair scheidbaar te maken. Als de data niet gescheiden kan worden door één rechte maar door twee halfrechten wordt een hidden layer toegevoegd. Deze laag splitst de data op in 2 deeldomeinen waarin de data wel lineair scheidbaar is. De verborgen laag zal dus twee neuronen hebben.

Als de ligging van een punt geëvalueerd wordt ten opzichte van een rechte is de waarde ofwel negatief ofwel positief, onder de rechte of boven de rechte respectievelijk. Nu komt de ReLU-activatiefunctie van pas. Voor beide halfrechten werkt de ReLU in op deze evaluatie van positie ten opzichte van de rechte. Zo zullen alle punten onder de rechte de waarde 0 toegewezen krijgen terwijl alle punten boven de rechte een strikt positieve waarde krijgen. De data wordt lineair scheidbaar door de waarden van de twee neuronen te sommeren. Voor punten die boven de rechten liggen is die som steeds positief, voor punten eronder is de steeds nul. Nu de data lineair scheidbaar is kan het Perceptron er wel succesvol mee overweg.[7]

6. IPLANT

6.1. Belang van het onderzoek

Het belangrijkste doel van het onderzoek is een studie opzetten naar de effecten van klimaatopwarming op planten. Zo kan men een inschatting maken over hoe de planten zullen evolueren in de toekomst. Het is nog niet duidelijk of de aanpassingen positief, wanneer ze helpen tegen de klimaatopwarming, of negatief zijn. Het effect van de opwarming van de Aarde wordt bestudeerd door het vergelijken van bladeren van tientallen jaren geleden

en bladeren van hedendaagse planten. Door het onderzoek kan men ook inzicht krijgen in andere belangrijke effecten. Zo kan ook een inschatting gemaakt worden welke planten zullen overleven en welke planten zullen uitsterven. Bij stijgende temperaturen blijven de huidmondjes van planten gedurende een kortere periode open, waardoor per huidmondje minder CO₂ opgenomen kan worden.

6.2. Verkrijgen van data

In het project wordt gebruikgemaakt van duizenden foto's om zo een neurale netwerk goed te trainen. Echter is het verkrijgen van dit soort foto's en een juiste dataset creëren geen gemakkelijk taak.

Wanneer men van de plant het bovenste laagje probeert los te maken om deze onder een microscoop te kunnen leggen botst men op een probleem. Het laagje dat men met de hand kan verwijderen van de plant is te dik. Hierdoor is het laagje onder de microscoop te dik waardoor de huidmondjes niet gedetecteerd kunnen worden. Om dit op te lossen maakt men gebruik van een andere techniek. Deze nieuwe techniek bestaat erin nagellak op de plant uit te smeren en deze te laten drogen. Daarna verwijdert men de nagellak van de plant. Op deze manier blijft enkel de bovenste laag aan de nagellak plakken en kan men de stomata beter detecteren. Het is belangrijk dat er gebruik wordt gemaakt van doorzichtige kleurloze nagellak om geen effecten van de nagellak op het resultaat te verkrijgen. Voor het creëren en trainen van een neurale netwerk wordt gebruikgemaakt van een op deze manier gemaakte dataset. [7]

6.3. Tellen van huidmondjes

Om resultaten te verkrijgen over de verandering van het aantal huidmondjes is het belangrijk dat deze op een correcte manier worden geteld. Het is veel werk om voor duizenden planten en foto's de stomata allemaal met de hand te bepalen. In plaats daarvan wordt gebruikgemaakt van een convolutioneel neurale netwerk. Bij het tellen van het netwerk is het ook belangrijk om het begrip stomatale densiteit te introduceren.

6.4. Stomatale densiteit

De stomatale densiteit wordt gedefinieerd als een hoeveelheid huidmondjes op een bepaalde oppervlakte-eenheid. Op de gekozen oppervlakte worden de huidmondjes geteld. Na het tellen worden het aantal huidmondjes gedeeld door de oppervlakte waarna we de stomatale densiteit verkrijgt. De oppervlakte-eenheid die

het meest gebruikt wordt bij het tellen van stomata is μm^2 . De afstand wordt gemeten in micrometer omdat de gemiddelde grootte van een stomata ligt op 17,7 micrometer in de lengte en 6,7 micrometer in de breedte. Dit proces wordt meerdere keren herhaald bij elke plant. Van al deze verschillende waarden wordt een gemiddelde genomen om zo een stomatale densiteit voor die plant te bepalen. De stomatale densiteit kan daarna vergeleken worden met andere soorten of planten van enkele jaren geleden. Zo is de stomatale densiteit een indicatie voor de groei of afname van het aantal huidmondjes.[21][22]

Voor het tellen van de densiteit moeten we eerst weten hoe groot de foto is. Het is dan ook handig om een schaal toe te voegen aan de afbeelding. Het objectief en de vergroting van de microscoop hebben een impact op de oppervlakte. Als de vergroting groter wordt, wordt de oppervlakte kleiner. Als men aan het neurale netwerk de grootte van elke foto weergeeft is het gemakkelijk om de densiteit te berekenen door de meegegeven oppervlakte en het aantal getelde stomata.[21][22]

6.5. Detectie van stomata

Het convolutioneel neurale netwerk om stomata op te sporen bij foto's van bladeren bestaat uit een lange reeks aan commando's, geschreven in de programmeertaal Python. Hierin zijn er verschillende parameters die aangepast kunnen worden om zo een beter en sneller resultaat te verkrijgen. Er wordt gestreefd naar detectie van zoveel mogelijk correcte stomata in een zo kort mogelijk tijdsinterval. Hieronder worden enkele van deze parameters overlopen.

6.5.1. Parameters

De eerste parameter die aangepast kan worden is het aantal neuronen. Neuronen verwijzen naar zenuwcellen en deze zijn dus het zogenoemde zenuwstelsel van het neurale netwerk. Het neurale netwerk is dus een verbinding van neuronen. Hiervoor geldt: des te meer, des te meer gewichten er aangepast kunnen worden. Op deze manier kan het netwerk een accuratere beslissing nemen.[7]

De tweede parameter is het aantal epochs, wat periode, tijdsgewricht betekent. Dit verwijst dus naar het aantal keer het trainingsproces doorlopen wordt. Een groot aantal epochs neemt wel veel tijd in beslag, waardoor het vrij lang kan duren voordat de resultaten verkregen zijn. Het netwerk moet voldoende iteraties ondergaan zodat er geen underfitting optreedt, maar mag ook niet te veel epochs ondergaan omdat dan overfitting kan voorkomen. Underfitting komt voor wanneer het netwerk nog niet voldoende getraind is. Overfitting komt voor wanneer het netwerk te goed getraind is op de trainingsdata, waardoor deze slecht presteert op de validatiedata en de uiteindelijke classificatie. Het is dus noodzakelijk een goede balans te vinden tussen de correctheid van het classificatieproces en het aantal epochs.[7]

Een derde waarde die bepaald moet worden is de learning rate. De learning rate bepaalt hoe snel of traag een neurale netwerk leert. De parameter beduidt de hoeveelheid dat de gewichten van het model veranderen tijdens elke stap in het proces. De learning rate wordt bijna altijd gekozen tussen 0.0 en 1.0. Het is noodzakelijk een goede waarde te vinden want bij een te hoge learning rate kan het zijn dat het resultaat te rap convergeert naar één bepaalde waarde, bij een te lage waarde kan het proces vastlopen. Het is ook belangrijk te weten dat de learning rate in verband staat met het aantal gekozen epochs want bij een te lage waarde van de learning rate moet een hogere waarde epochs gekozen worden, dit omdat de gewichten amper aangepast worden, waardoor we het proces meer moeten laten doorlopen.[7]

Bij de aanpassingen aan het neurale netwerk speelt gradient descent een belangrijke rol. Door middel van gradiënt descent gaat men op zoek naar het minimum aan fouten. Dit algoritme zoekt een minimum door herhalende stappen te nemen tegen de richting van het verloop in. Bij elke stap gebeurt een aanpassing met de grootte van de learning rate.[7]

We kunnen ook de parameter van de batch size bepalen. Het neurale netwerk wordt geüpdatet elke keer de batch size gelijk is aan het aantal samples die we gebruiken. Hoe kleiner de batch size, hoe meer het netwerk wordt geüpdatet, hoe accurater.[7]


De voorlaatste parameter is de shift. Dit bepaalt de stapgrootte, het aantal pixels, van hoe de convolutiefilter opschuift voordat men een nieuwe patch van 120 op 120 gebruikt bij de classificatie. Een kleinere waarde voor de shift zorgt dus voor een accurater systeem, maar wel voor een langere tijdsduur. Te klein kan namelijk betekenen dat een stomata meerdere keren wordt gedetecteerd, wat overbodig is. Een afweging is dus belangrijk

De laatste waarde die we handmatig hebben ingesteld is de threshold. Dit betekent drempel en wordt dus ook zo gebruikt in ons neurale netwerk. Hoe hoger we de threshold instellen, hoe 'strenger' ons systeem zal zijn voor wat al dan niet een stomata is. Het is dus noodzakelijk dat we een juiste waarde kiezen hiervoor, we mogen niet te streng en zeker niet te mild zijn. [7]

Wanneer men geen optimale waarde kiest voor zowel het aantal neuronen, als de threshold, als de learning rate, kunnen er vals positieven en vals negatieven opduiken. Er is sprake van vals positief wanneer men een zogezegd huidmondje detecteert die eigenlijk geen huidmondje is. Dit kan voorkomen als de accuraatheid van het systeem te laag is, het netwerk neemt geen voldoende strenge beslissing om het huidmondje al dan niet aan te duiden. Daarnaast kan er ook sprake zijn van vals negatieven, dit wanneer men een echt huidmondje niet aanduidt. Dit wil zeggen dat het systeem te accuraat is ingesteld en dat het te streng is waardoor het sommige stomata niet als een stomata detecteert. Zo is het belangrijk een zo optimaal neurale netwerk te creëren met de passende parameters.[7]

6.4.2. *Structuur netwerk*

Na het bepalen van al deze voorgaande parameters is het ook belangrijk de structuur van het netwerk zeer goed te bekijken. Het aantal convolutionele lagen van het netwerk moest namelijk ook bepaald worden. Wij kozen ervoor om gebruik te maken van vier convolutionele lagen, deze met elk respectievelijk 32, 64, 128 en 256 convolutionele filters. Door het gebruik van meerdere van die lagen bekomen we een netwerk dat des te meer gedetailleerde informatie verkrijgt over de foto's.



Figuur 5: Structuur eigen neuraal netwerk

Tussenin de verschillende convolutionele lagen wordt er aan max pooling gedaan. Max pooling zorgt ervoor dat de maximale waarde uit een kleinere vierkante deelmatrix van 2 op 2 gekozen wordt om deze toe te voegen aan de matrix en hiermee verder te werken. Na de max pooling volgt er een flatten layer. Deze plaatst de drie overgebleven naast elkaar in een nieuwe matrix naast elkaar.

Na de vier convolutionele lagen volgen er nog drie dense layers. Dense layers zijn neurale netwerklagen waarbij elk neuron van de dense layer input krijgt van de vorige laag om bij de laatste laag een finaal resultaat te bekomen. We kozen om respectievelijk een dense layer van 2048 neuronen te gebruiken en daarna een dense layer van 1024 neuronen.

Zowel de convolutionele lagen als de dense layers bevatten allemaal een activatiefunctie. Alle convolutionele lagen en de eerste dense layer bevatten de ReLU activatie functie, wat verwijst naar 'Rectified Linear Unit'. Wanneer de input positief is, geeft deze dezelfde output als input, wanneer de input negatief is, verkrijgt men altijd nul als output.

De laatste dense layer heeft als activatiefunctie de sigmoïd functie. Hierbij gebruikt men de input als x-waarde en is het verkregen resultaat de output-waarde. Deze output zal door bovenstaand voorschrift altijd een waarde aannemen tussen nul en één. Bij deze laatste activatiefunctie speelt de threshold een belangrijke rol. Wanneer men een output verkrijgt die hoger is dan de threshold, zal dit beschouwd worden als stomata en dus aangeduid worden. Wij kozen voor een threshold van 0.7, dit betekent dat alle output-waarden hoger of gelijk aan 0.7 als stomata worden beschouwd.

REFERENTIES

- [1] Convolutioneel neuraal netwerk - Convolutional neural network . (2020, december 13). Opgehaald van qaz: https://nl.qaz.wiki/wiki/Convolutional_neural_network
- [2] Training Data. (sd). Opgehaald van techopedia: <https://www.techopedia.com/definition/33181/training-data#:~:text=The%20training%20data%20is%20an,called%20validation%20and%20testing%20sets.>
- [3] Invoerapparaat. (2019, november 5). Opgehaald van Wikipedia: <https://nl.wikipedia.org/wiki/Invoerapparaat#:~:text=Onder%20een%20invoerapparaat%20wordt%20elk,aanraak scherm%2C%20scanners%20en%20digitale%20camera's.>
- [4] Wat is het broeikaseffect? (sd). Opgehaald van milieucentraal: <https://www.milieucentraal.nl/klimaat-en-aarde/klimaatverandering/wat-is-het-broeikaseffect/>
- [5] Wikipedia-bijdragers. (2020b, juni 21). Neuraal netwerk. Wikipedia. https://nl.wikipedia.org/wiki/Neuraal_netwerk
- [6] Wikipedia contributors. (2020, 10 december). Neural network. Wikipedia. https://en.wikipedia.org/wiki/Neural_network
- [7] Natacha Gesquière, Francis wyffels. (2020) Kunstmatige Intelligentie, Klimaatverandering, Stomata: KIKS Leerlingencursus versie 1.0
- [8] Wikipedia-bijdragers. (2020, 23 maart). Machinaal leren. Wikipedia. https://nl.wikipedia.org/wiki/Machinaal_leren
- [9] Wikipedia-bijdragers. (2020, 16 december). Machine learning. Wikipedia. https://en.wikipedia.org/wiki/Machine_learning
- [10] Natacha Gesquière, wyffels Francis. Notebooks KIKS aangereikt via <https://kiks.ilabt.imec.be/jupyter/hub/spawn?next=%2Fjupyter%2Fhub%2Fuser%2F0aacc4d-6c6e-4324-9379-ef4662023c11%2F>
- [11] Wikipedia-bijdragers. (2020, 13 december). Deep learning. Wikipedia. https://en.wikipedia.org/wiki/Deep_learning
- [12] What is artificial intelligence? (sd). Opgehaald van NetApp: <https://www.netapp.com/artificial-intelligence/what-is-artificial-intelligence/>
- [13] Ng, A. (sd). Machine Learning. Opgehaald van coursera: <https://www.coursera.org/learn/machine-learning>
- [14] Hidden Layer (sd). Opgehaald van techopedia: <https://www.techopedia.com/definition/33264/hidden-layer-neural-networks>
- [15] Hargrave, M. (2020, november 24). Deep Learning. Opgehaald van Investopedia: <https://www.investopedia.com/terms/d/deep-learning.asp>
- [16] Convolution. Opgehaald van Wikipedia: <https://en.wikipedia.org/wiki/Convolution>
- [17] Classificatie. Opgehaald van Wikipedia: <https://nl.wikipedia.org/wiki/Classificatie#:~:text=Classificatie%20in%20engere%20zin%20is,geformaliseerde%20resultaat%20van%20die%20activiteiten>
- [18] Relu. (2019). <https://machinelearningmastery.com/rectified-linear-activation-function-for-deep-learning-neural-networks/>
- [19] Nature Education, „Photosynthetic Cells,”. Opgehaald van: <https://www.nature.com/scitable/topicpage/photosynthetic-cells-14025371/>. [Geopend 20 oktober 2020].
- [20] J. A. Bassham en H. Lambers, „Photosynthesis,” [Online]. Opgehaald van: <https://www.britannica.com/science/photosynthesis/Basic-products-of-photosynthesis.> [Geopend 20 oktober 2020].

- [21] S. Bhugra, D. Mishra, A. Anupama, S. Chaudhury, B. Lall, A. Chugh en V. Chinnusamy, „Deep Convolutional Neural Networks based Framework for Estimation of Stomata Density and Structure from Microscopic Images,” 2018. [Online]. Opgehaald van:
https://openaccess.thecvf.com/content_ECCVW_2018/papers/11134/Bhugra_Deep_Convolutional_Neural_Netw_orks_based_Framework_for_Estimation_of_Stomata_ECCVW_2018_paper.pdf.
- [22] Fetter, S. Eberhardt, R. S. Barclay, S. Wing en S. R. Keller, „StomataCounter: a neural network for automatic stomata indentification and counting,” 2019. Opgehaald van:
<https://nph.onlinelibrary.wiley.com/doi/epdf/10.1111/nph.15892>.
- [23] A. M. Hetherington en F. I. Woodward, „The role of stomata in sensing and driving environmental change,” 2003. Opgehaald van:
https://www.researchgate.net/publication/10603718_Hetherington_A_M_Woodward_F_I_The_role_of_stomata_in_sensing_and_driving_environmental_change_Nature_424_901-908.
- [24] H. G. Jones, „Stomatal control of photosynthesis and transpiration,” 1997. [Online]. Opgehaald van:
https://d1wqtxts1xzle7.cloudfront.net/39885093/Stomatal_control_of_photosynthesis_and_t20151110-28876-1xps6z3.pdf?1447203181=&response-content-disposition=inline%3B+filename%3DStomatal_control_of_photosynthesis_and_t.pdf&Expires=1603546848&Signature=gOoS
- [25] Masterclass. Opgehaald van: <https://www.masterclass.com/articles/understanding-cultural-bias#what-is-cultural-bias>
- [26] EM Onderzoek, Opgehaald van: <https://www.emonderzoek.nl/wat-is-bias/>